

KG_QA_Dataset 测试结果报告

1. 测试概述

本报告总结了在自建知识图谱问答数据集(kg_qa_dataset)上的测试结果，对比了两个不同规模的语言模型在图约束推理任务中的表现。

测试日期: 2026年1月数据集: kg_qa_dataset (自建)

评估模型: gpt-4o, qwen3-235b

2. 测试模型

模型名称	参数规模	测试环境
Qwen2-0.5B-Instruct	0.5B	本地机器
Llama-3.1-8B-Instruct	8B	服务器

3. 测试流程说明

本测试分为两个阶段：

- GenPaths 阶段:** 使用 图谱专用小模型 生成候选推理路径
- KGQA 阶段:** 使用 GPT-4o 或 qwen3-235b 基于生成的路径进行答案推理

4. GenPaths 阶段测试结果

4.1 GCR-Qwen2-0.5B-Instruct 路径生成结果

K值	Accuracy (%)	Hit (%)	Answer F1 (%)	Answer Precision (%)	Answer Recall (%)	Path F1 (%)	Path Precision (%)	Path Recall (%)
k=3	31.0	31.0	1.42	1.17	2.0	29.65	29.08	31.0
k=5	35.0	35.0	3.30	2.14	7.5	30.54	29.23	35.0
k=10	37.0	37.0	5.69	3.25	24.0	25.62	21.55	37.0

4.2 GCR-Llama-3.1-8B-Instruct 路径生成结果

K值	Accuracy (%)	Hit (%)	Answer F1 (%)	Answer Precision (%)	Answer Recall (%)	Path F1 (%)	Path Precision (%)	Path Recall (%)
k=3	35.0	35.0	2.58	2.03	3.8	33.21	32.45	35.0
k=5	39.0	39.0	4.72	3.21	9.2	34.87	33.56	39.0
k=10	42.0	42.0	8.15	5.12	28.5	28.93	24.78	42.0

5. KGQA 阶段测试结果

5.1 Qwen2-0.5B-Instruct 测试结果

K值	Accuracy (%)	Hit (%)	F1 Score (%)	Precision (%)	Recall (%)
k=3	34.0	34.0	31.92	30.92	34.0
k=5	34.5	34.5	33.03	32.38	34.5
k=10	34.4	34.4	26.21	23.99	34.4

关键发现:

- 最佳准确率出现在 k=5，达到 34.5%
- k=10 时 F1 和 Precision 显著下降，表明路径数量增加导致噪声增多
- Recall 与 Accuracy 保持一致，说明模型能够覆盖正确答案

5.2 Llama-3.1-8B-Instruct 测试结果

K值	Accuracy (%)	Hit (%)	F1 Score (%)	Precision (%)	Recall (%)
k=3	32.0	32.0	30.08	29.12	32.0
k=5	34.0	34.0	32.54	31.79	34.0
k=10	37.0	37.0	28.49	25.97	37.0

关键发现:

- 准确率随 k 值增加而提升，k=10 时达到最高 37.0%
- 相比 Qwen2-0.5B，在 k=10 时表现更优，提升 2.6 个百分点
- F1 和 Precision 在 k=10 时同样下降，但整体准确率更高