

20260206工作报告

KG_QA_Dataset 测试结果报告

1. 测试概述

本报告总结了在自建知识图谱问答数据集(kg_qa_dataset)上的测试结果，对比了两个不同规模的语言模型在图约束推理任务中的表现。

测试日期: 2026年1月数据集: kg_qa_dataset (自建)

评估模型: gpt-4o, qwen3-235b

2. 测试模型

模型名称	参数规模	测试环境
Qwen2-0.5B-Instruct	0.5B	本地机器
Llama-3.1-8B-Instruct	8B	服务器

3. 测试流程说明

本测试分为两个阶段：

- GenPaths 阶段:** 使用 图谱专用小模型 生成候选推理路径
- KGQA 阶段:** 使用 GPT-4o 或 和qwen3-235b 基于生成的路径进行答案推理

4. GenPaths 阶段测试结果

4.1 GCR-Qwen2-0.5B-Instruct 路径生成结果

K值	Accuracy (%)	Hit (%)	Answer F1 (%)	Answer Precision (%)	Answer Recall (%)	Path F1 (%)	Path Precision (%)	Path Recall (%)
k=3	31.0	31.0	1.42	1.17	2.0	29.65	29.08	31.0
k=5	35.0	35.0	3.30	2.14	7.5	30.54	29.23	35.0
k=10	37.0	37.0	5.69	3.25	24.0	25.62	21.55	37.0

4.2 GCR-Llama-3.1-8B-Instruct 路径生成结果

K值	Accuracy (%)	Hit (%)	Answer F1 (%)	Answer Precision (%)	Answer Recall (%)	Path F1 (%)	Path Precision (%)	Path Recall (%)
k=3	35.0	35.0	2.58	2.03	3.8	33.21	32.45	35.0

K值	Accuracy (%)	Hit (%)	Answer F1 (%)	Answer Precision (%)	Answer Recall (%)	Path F1 (%)	Path Precision (%)	Path Recall (%)
k=5	39.0	39.0	4.72	3.21	9.2	34.87	33.56	39.0
k=10	42.0	42.0	8.15	5.12	28.5	28.93	24.78	42.0

5. KGQA 阶段测试结果

5.1 Qwen2-0.5B-Instruct 测试结果

K值	Accuracy (%)	Hit (%)	F1 Score (%)	Precision (%)	Recall (%)
k=3	34.0	34.0	31.92	30.92	34.0
k=5	34.5	34.5	33.03	32.38	34.5
k=10	34.4	34.4	26.21	23.99	34.4

关键发现:

- 最佳准确率出现在 k=5，达到 34.5%
- k=10 时 F1 和 Precision 显著下降，表明路径数量增加导致噪声增多
- Recall 与 Accuracy 保持一致，说明模型能够覆盖正确答案

5.2 Llama-3.1-8B-Instruct 测试结果

K值	Accuracy (%)	Hit (%)	F1 Score (%)	Precision (%)	Recall (%)
k=3	32.0	32.0	30.08	29.12	32.0
k=5	34.0	34.0	32.54	31.79	34.0
k=10	37.0	37.0	28.49	25.97	37.0

关键发现:

- 准确率随 k 值增加而提升，k=10 时达到最高 37.0%
 - 相比 Qwen2-0.5B，在 k=10 时表现更优，提升 2.6 个百分点
 - F1 和 Precision 在 k=10 时同样下降，但整体准确率更高
-

更换数据集

1.1 原有数据集存在的问题

在项目初期使用的自建数据集 (kg_qa_dataset) 存在以下局限性:

- **数据质量不高:** 知识图谱的关系种类较少, 覆盖范围有限
- **问答对质量较低:** 生成的问答对缺乏多样性和复杂性
- **缺乏标准评估:** 没有标准的测试集进行对比验证
- **领域覆盖不足:** 数据集规模和领域覆盖度不够

1.2 选择COKG_QA数据集的原因

为了解决上述问题, 我们选择了COKG_QA数据集作为新的测试基准:

- **领域专业性:** 基于医疗领域的中文知识图谱, 具有较高的专业性
- **自带问答对:** 数据集包含高质量的人工标注问答对
- **多跳推理支持:** 包含一跳、两跳、三跳的推理数据, 可以测试不同复杂度的推理能力
- **标准化评估:** 作为公开数据集, 便于与其他方法进行对比

在新数据集上的工作

2.1 数据格式转换脚本开发

2.1.1 格式差异分析

COKG_QA数据集的原始格式与GCR框架要求的格式存在显著差异:

COKG_QA原始格式:

- 知识图谱: JSONL格式, 每行为 `[头实体, 关系, 尾实体, [类型]]`
- 问答对: TXT格式, 每行为 `问题\t答案\t类型`
- 答案分隔: 使用 `##` 分隔多个答案

GCR要求格式:

```
{
  "id": "样本ID",
  "question": "问题文本",
  "answer": ["答案1", "答案2"],
  "q_entity": ["问题实体"],
  "a_entity": ["答案实体"],
  "graph": [["头", "关系", "尾"], ...]
}
```

2.1.2 转换脚本实现

开发了 `src/gendata/convert_cokg_qa.py` 脚本, 实现以下核心功能:

1. 多答案实体支持

- 自动为每个答案实体查找最短路径

- 确保所有答案实体都包含在子图中
- 不会因为找到一个答案就停止搜索

2. 最短路径查找算法

- 使用BFS（广度优先搜索）算法
- 从问题实体到每个答案实体查找最短路径
- 最大搜索深度: 5跳
- 支持多个问题实体和多个答案实体的组合

3. 智能子图构建策略

第1步：添加问题→答案的最短路径（核心路径）
第2步：添加问题实体的2跳邻居（上下文信息）
第3步：添加答案实体的2跳邻居（答案相关信息）

4. 性能优化措施

- 邻居数限制: 每个实体最多200个邻居
- 预先构建实体索引，加快查找速度
- 流式写入JSONL格式，节省内存

2.2 模型泛化性测试

2.2.1 测试模型配置

测试模型1: GCR-Qwen2-0.5B-Instruct（作者微调版本）

- 基础模型: Qwen2-0.5B-Instruct
- 微调数据: 作者原始数据集（kg_qa_dataset）
- 微调方法: LoRA或全量微调
- 特点: 在原始数据集上训练，学习了生成 路径和 <PATH> 标签的能力

测试模型2: Qwen2.5-0.5B-Instruct（原生未微调）

- 基础模型: Qwen2.5-0.5B-Instruct
- 微调状态: 未微调
- 特点: 通用语言模型，未经过图推理任务训练

2.2.2 测试结果与问题分析

问题1: 微调模型泛化能力不佳

在GCR-Qwen2-0.5B-Instruct模型上测试COKG_QA数据集时，发现以下问题：

1. 生成不相关的英文内容

- 现象: 模型在中文医疗数据集上生成英文路径或实体
- 原因: 原始训练数据可能包含英文数据集（如WebQSP、CWQ）
- 影响: 生成的路径与中文医疗知识图谱不匹配

2. 生成非预期路径

- 现象: 生成的路径与用户查询不相关

- 原因: 模型过拟合到原始数据集的实体和关系分布
- 影响: 无法正确理解新领域的问题意图

3. 路径命中率低

- 数据: 路径命中率仅约40% (Path Recall)
- 对比: 在原始数据集上可达到更高的命中率
- 结论: 模型在新领域数据上泛化能力不足

问题2: 原生模型无法生成约束路径

在Qwen2.5-0.5B-Instruct原生模型上测试时:

1. 无法生成 `<PATH>` 标签

- 现象: 模型不知道需要生成 `<PATH></PATH>` 标签
- 原因: 未经过图推理任务的微调训练
- 影响: 图约束解码机制无法启动

2. 完全无约束的文本生成

- 现象: 模型生成自由文本, 而非结构化路径
- 原因: 约束推理只在 `<PATH></PATH>` 标签内部生效
- 影响: 无法利用知识图谱结构进行约束推理

测试结论:

- 微调模型在新领域数据上存在严重的泛化问题
- 原生模型缺乏图推理任务的基本能力
- 需要在COKG_QA数据集上重新微调模型

2.3 多答案实体路径生成问题

在医疗知识图谱问答中, 许多问题的答案包含多个实体, 例如:

示例问题: "糖尿病的并发症有哪些? "

答案实体:

- 糖尿病肾病
- 糖尿病视网膜病变
- 糖尿病足
- 糖尿病神经病变
- 心血管疾病

推理要求:

- 需要找到从"糖尿病"到每个并发症的推理路径
- 每条路径可能经过不同的关系和中间实体
- 模型需要生成多条路径才能覆盖所有答案

技术挑战

1. 路径数量控制

- 如何确定生成多少条路径 (k值)
- 路径过少: 无法覆盖所有答案实体
- 路径过多: 引入噪声, 降低精确度

2. 路径质量保证

- 确保每条路径都指向不同的答案实体
- 避免生成重复或相似的路径
- 保持路径的多样性和相关性

3. 评估指标设计

- 答案实体覆盖率: 生成的路径覆盖了多少答案实体
- 路径准确率: 生成的路径是否正确连接问题和答案
- 答案完整性: 是否找到了所有正确答案

2.3.3 当前解决方案

数据转换层面 (已实现) :

- `convert_cokg_qa.py` 脚本已支持多答案实体
- 使用BFS算法为每个答案实体查找最短路径
- 统计答案实体覆盖率, 确保数据质量

模型生成层面 (进行中) :

- 使用Group Beam Search生成多条候选路径
- 整合不同答案, 输出实体列表

评估指标:

- Path Recall: 生成的路径中有多少覆盖了真实答案实体
- Answer Coverage: 答案实体的覆盖比例
- Answer F1: 综合考虑答案的精确率和召回率

知识图谱专用LLM微调流程说明

微调方法

项目支持两种微调方式:

1. LoRA微调 (参数高效)

配置示例:

```
BATCH_SIZE=50
USE_PEFT=True
EPOCH=20
GRADIENT_CHECKPOINTING=False
GRADIENT_ACCUMULATION_STEPS=1
auto_find_batch_size=True
CONFIG="accelerate_configs/multi_gpu.yaml"
```

2. 全量微调 (Full Fine-tuning)

配置示例：

```
BATCH_SIZE=4
USE_PEFT=False
EPOCH=3
GRADIENT_CHECKPOINTING=True
GRADIENT_ACCUMULATION_STEPS=16
auto_find_batch_size=False
CONFIG="accelerate_configs/deepspeed_zero3.yaml"
```

支持的模型

项目已测试以下模型：

Qwen系列

```
MODEL_PATH=Qwen/Qwen2-0.5B-Instruct
ATTN_IMP=flash_attention_2
RESPONSE_TEMPLATE="<|im_start|>assistant"
```

Llama系列

```
# Llama 2
MODEL_PATH=meta-llama/Llama-2-7b-chat-hf
RESPONSE_TEMPLATE="[/INST]"

# Llama 3.1
MODEL_PATH=meta-llama/Meta-Llama-3.1-8B-Instruct
RESPONSE_TEMPLATE="<|start_header_id|>assistant<|end_header_id|>"
```

注意：不同模型需要配置对应的 `RESPONSE_TEMPLATE`，用于标识助手回复的起始位置。

数据处理流程

数据格式

训练数据使用HuggingFace Datasets格式，存储在 `data/shortest_path_index/` 目录下。

数据集字段：

- `question`: 问题文本

- `q_entity`: 问题中的主题实体列表
- `a_entity`: 答案实体列表
- `ground_truth_paths`: 真实推理路径列表（非原始数据集中的数据，是根据头尾实体在图谱中查找最短路径得到的）

路径格式： 每条路径是三元组列表 `[(head, relation, tail), ...]`

数据预处理

代码位置: [workflow/finetune_kg_specialized_llm.py:154-185](#)

处理步骤：

1. 加载数据集

```
data_list = [
    datasets.load_from_disk(data_path)
    for data_path in script_args.data_path_list
]
dataset = datasets.concatenate_datasets(data_list)
```

2. 格式化输入

使用提示模板：

```
Reasoning path is a sequence of triples in the KG that connects
the topic entities in the question to answer entities.
Given a question, please generate some reasoning paths in the KG
starting from the topic entities to answer the question.

# Question:
{question}
# Topic entities:
{entities}
```

3. 路径转换

使用 `path_to_string` 函数 ([src/utils/utils.py:34-44](#)) 将路径转换为字符串：

```
def path_to_string(path: list) -> str:
    result = ""
    for i, p in enumerate(path):
        if i == 0:
            h, r, t = p
            result += f"{h} -> {r} -> {t}"
        else:
            _, r, t = p
            result += f"-> {r} -> {t}"
    return result.strip()
```

示例输出：

```
<PATH>实体A -> 关系1 -> 实体B -> 关系2 -> 实体C</PATH>
```


4. 构建训练样本

每条路径生成一个训练样本：

```
chat = [
    {"role": "user", "content": raw_input},
    {"role": "assistant", "content": response},
]
final_input = tokenizer.apply_chat_template(
    chat, tokenize=False, add_generation_prompt=False
)
```

5. 特殊Token

添加路径标记符：

- `<PATH>`：路径开始标记
- `</PATH>`：路径结束标记
- `<PAD>`：填充标记（如果模型没有）

数据采样

- 参数 `n_path_per_sample=10` 控制每个问题采样的路径数量
- 每条路径独立作为一个训练样本
- 空路径会被过滤掉

后续工作计划

1. 在COKG_QA数据集上微调模型

- 使用转换后的训练集进行微调
- 测试LoRA和全量微调的效果
- 对比不同规模模型的性能

2. 优化多答案路径生成

- 实现答案实体覆盖率评估
- 调整k值选择策略
- 改进路径去重和排序算法